Adatbázisok 1.
Relációs adatbázis tervezés – 4. rész

Funkcionális függőségek

Felbontások

Normálformák

Relációs sémák tervezése

- Cél: az anomáliák és a redundancia megszüntetése.
  - *Módosítási anomália*
  - *Törlési anomália*
  - *Beszúrási anomália*

Példa: rosszul tervezett séma

Főnökök(<u>név</u>, cím, <u>kedveltTeák</u>, gyártó, kedvencTea)

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	???	E. G.	Tetley	???
Spock	Enterprise	Brisk	???	Brisk

Redundáns adat, a ??? helyén a
név -> cím kedvencTea és kedveltTeák -> gyártó FF-ek
felhasználásával tudjuk, mi szerepel.

A rosszul tervezettség anomáliákat is eredményez

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	Voyager	E. G.	Tetley	E. G.
Spock	Enterprise	Brisk	Lipton	Brisk

- Módosítási anomália: ha Janeway-t *Judyra* módosítjuk, megtesszük-e ezt minden sornál?
- Törlési anomália: ha már senki sem szereti a Brisk teát, azt sem fogjuk tudni, hogy ki gyártotta.
- Beszúrási anomália: ha nem lehet ismeretlen a kedveltTeákra vonatkozó érték, akkor nem tudunk felvenni egy teákat nem kedvelő főnököt

Relációk felbontása

- R relációt, $\{A_1, A_2, \ldots, A_n\}$ attribútumokkal helyettesítsük $S(B_1, B_2, \ldots, B_m)$ és $T(C_1, C_2, \ldots, C_k)$ relációkkal úgy, hogy

1. $\{A_1, A_2, \ldots, A_n\} = \{B_1, B_2, \ldots, B_m\} \cup \{C_1, C_2, \ldots, C_k\}$
2. $S = \Pi_{B1, B2, \ldots, Bm}(R)$
3. $T = \Pi_{C1, C2, \ldots, Ck}(R)$

Veszteségmentes felbontás

- Ha $r = \Pi_{R1}(r) \,|X|\, \ldots \,|X|\, \Pi_{Rk}(r)$ teljesül, akkor az előbbi összekapcsolásra azt mondjuk, hogy veszteségmentes. Itt r egy R sémájú relációt jelöl és R attribútumainak részhalmazai az R1, …, Rk.
- $\Pi_{Ri}(r)$ jelentése: r sorai az Ri attribútumaira projektálva.
- Megjegyzés: könnyen látható, hogy $r \subseteq \Pi_{R1}(r) \,|X|\, \ldots \,|X|\, \Pi_{Rk}(r)$ mindig teljesül. (Miért?)

R

A	B	C
a	b	c
d	e	f
c	b	c

R_1

A	B
a	b
d	e
c	b

R_2

B	C
b	c
e	f

Példa

- A szétvágás után keletkező relációk összekapcsolása nem veszteségmentes:

R

A	B	C
a	b	c
c	b	e

R_1

A	B
a	b
c	b

R_2

B	C
b	c
b	e

Boyce-Codd normálforma

- *R* reláció *BCNF* normálformában van, ha minden *X ->Y* nemtriviális FF-re *R*-ben *X* szuperkulcs.
  - *Nemtriviális:* *Y* nem része *X*-nek.
  - *Szuperkulcs:* tartalmaz kulcsot (ő maga is lehet kulcs).

Példa

Főnökök(<u>név</u>, cím, <u>kedveltTeák</u>, gyártó, kedvencTea)

FF-ek: név->cím kedvencTea, kedveltTeák->gyártó

- Itt egy kulcs van: {név, kedveltTeák}.
- A baloldalak egyik FF esetén sem szuperkulcsok.
- Emiatt az *Főnökök* reláció nincs BCNF normálformában.

Még egy példa

Teák(<u>név</u>, gyártó, gyártóCím)

FF-ek: név->gyártó, gyártó->gyártóCím

- Az egyetlen kulcs {név} .
- név->gyártó nem sérti a BCNF feltételét, de a gyártó->gyártóCím függőség igen.

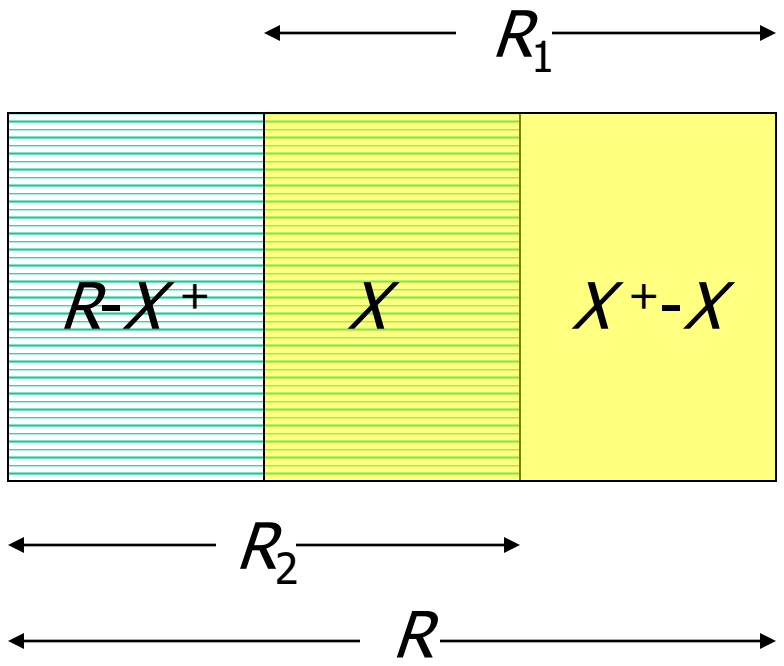
BCNF-re való felbontás

- Adott *R* reláció és *F* funkcionális függőségek.
- Van-e olyan *X* ->*Y* FF, ami sérti a BCNF-t?
  - Ha van olyan következmény FF *F*-ben, ami sérti a BCNF-t, akkor egy *F*-beli FF is sérti.
- Kiszámítjuk X^+-t:
  - Ha itt nem szerepel az összes attribútum, *X* nem szuperkulcs.

R dekomponálása *X* -> *Y* felhasználásával

- *R*-t helyettesítsük az alábbiakkal:
  1. $R_1 = X^+$.
  2. $R_2 = R - (X^+ - X)$.
- *Projektáljuk* a meglévő *F* -beli FF-eket a két új relációsémára.

Dekomponálási kép



Példa: BCNF dekompozíció

Főnökök(<u>név</u>, cím, <u>kedveltTeák</u>, gyártó, kedvencTea)

F = név->cím, név->kedvencTea,

kedveltTeák->gyártó

- Vegyük név->cím FF-t:
- $\{név\}^+ = \{név, cím, kedvencTea\}$.
- A dekomponált relációsémák:
  1. Főnökök1(<u>név</u>, cím, kedvencTea)
  2. Főnökök2(<u>név</u>, <u>kedveltTeák</u>, gyártó)

Példa -- folytatás

- Meg kell néznünk, hogy az Főnökök1 és Főnökök2 táblák BCNF-ben vannak-e.
- Az FF-ek projektálása könnyű.
- A Főnökök1(<u>név</u>, cím, kedvencTea), az FF-ek név->cím és név->kedvencTea.
  - Tehát az egyetlen kulcs: {név}, azaz az Főnökök1 BCNF-ben van.

Példa -- folytatás

- Az Főnökök2(<u>név</u>, <u>kedveltTeák</u>, gyártó) esetén az egyetlen FF

  kedveltTeák->gyártó, az egyetlen kulcs: {név, kedveltTeák}.
  - Sérül a BCNF.
- kedveltTeák$^+$ = {kedveltTeák, gyártó}, az *Főnökök2* felbontása:
  1. Főnökök3(<u>kedveltTeák</u>, gyártó)
  2. Főnökök4(<u>név</u>, <u>kedveltTeák</u>)

Példa -- befejezés

- Az *Főnökök* dekompozíciója tehát:
  1. Főnökök1(<u>név</u>, cím, kedvencTea)
  2. Főnökök3(<u>kedveltTeák</u>, gyártó)
  3. Főnökök4(<u>név</u>, <u>kedveltTeák</u>)
- A *Főnökök1* a főnökökről, a *Főnökök3* a teákról, a *Főnökök4* a főnökökről és kedvelt teáikról tartalmaz információt.

Példa – anomáliák?

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	Voyager	E. G.	Tetley	E. G.
Spock	Enterprise	Brisk	Lipton	Brisk

1. Főnökök1(<u>név</u>, cím, <u>kedvencTea</u>)
2. Főnökök3(<u>kedveltTeák</u>, gyártó)
3. Főnökök4(<u>név</u>, <u>kedveltTeák</u>)

név	**cím**	**kedvencTea**
Janeway	Voyager	E. G.
Spock	Enterprise	Brisk

kedveltTeák	**gyártó**
Brisk	Lipton
E. G.	Tetley

név	**kedveltTeák**
Janeway	Brisk
Janeway	E. G.
Spock	Brisk

Miért működik a BCNF?

- (R, F) esetén ha $R_1,\dots, R_k$ egy veszteségmentes felbontás, S_1, S_2 pedig R_1 veszteségmentes felbontása, akkor S_1, S_2, $R_2,\dots, R_k$ is veszteségmentes felbontás.
- Könnyen ellenőrizhető, hogy a BCNF felbontásos dián az R_1, R_2 veszteségmentes. Ehhez:

  Feladat: bizonyítsuk be, hogy ha az R(A, B, C) reláció esetén $B \rightarrow C$ teljesül, akkor az R_1(A, B), R_2(B, C) felbontás mindig veszteségmentes.
- Minden két attribútumú séma BCNF normálformában van.
- A fentiekkel igazolható:
- Az algoritmus tehát valóban veszteségmentes felbontást ad, ám sajnos exponenciális lépésszámú is lehet a függőségek vetítése miatt.

Chase-teszt veszteségmentességhez I.

- Példa: adott R(A, B, C, D), F = { A → B, B → C, CD → A } és az

  R_1(A, D), R_2(A, C), R_3(B, C, D) felbontás. Kérdés veszteségmentes-e a felbontás?

- Vegyük R_1 |X| R_2 |X| R_3 egy *t* = (a, b, c, d) sorát. Bizonyítani kell, hogy *t* R egy sora. A következő tablót készítjük el:

A	B	C	D
a	b_1	c_1	d
a	b_2	c	d_2
a_3	b	c	d

Itt pl. az (a, b_1, c_1, d) sor azt jelzi, hogy R-nek van olyan sora, aminek R_1-re való levetítése (a, d), ám ennek a B és C attribútumokhoz tartozó értéke ismeretlen, így egyáltalán nem biztos, hogy a t sorról van szó.

Chase-teszt veszteségmentességhez II.

- Az F-beli függőségeket használva egyenlővé tesszük azokat a szimbólumokat, amelyeknek ugyanazoknak kell lennie, hogy valamelyik függőség ne sérüljön.
  - Ha a két egyenlővé teendő szimbólum közül az egyik index nélküli, akkor a másik is ezt az értéket kapja.
  - Két indexes szimbólum esetén a kisebbik indexű értéket kapja meg a másik.
  - A szimbólumok minden előfordulását helyettesíteni kell az új értékkel.
- Az algoritmus véget ér, ha valamelyik sor t-vel lesz egyenlő, vagy több szimbólumot már nem tudunk egyenlővé tenni.

Chase-teszt veszteségmentességhez III.

A	B	C	D
a	b_1	c_1	d
a	b_2	c	d_2
a_3	b	c	d

$A \rightarrow B$



A	B	C	D
a	b_1	c_1	d
a	b_1	c	d_2
a_3	b	c	d

$B \rightarrow C$



A	B	C	D
a	b_1	c	d
a	b_1	c	d_2
a_3	b	c	d

$CD \rightarrow A$



A	B	C	D
a	b_1	c	d
a	b_1	c	d_2
a	b	c	d

Chase-teszt veszteségmentességhez IV.

- Ha *t* szerepel a tablóban, akkor valóban *R*-nek egy sora, és mivel *t*-t tetszőlegesen választottuk, ezért a felbontás veszteségmentes.
- Ha nem kapjuk meg *t*-t, akkor viszont a felbontás nem veszteségmentes.
- Példa: R(A, B, C, D), F = { B → AD }, a felbontás: R_1(A, B), R_2(B, C), R_3(C, D).

A	B	C	D
a	b	c_1	d_1
a_2	b	c	d_2
a_3	b_3	c	d

B → AD



A	B	C	D
a	b	c_1	d_1
a	b	c	d_1
a_3	b_3	c	d

Itt az eredmény jó ellenpélda, hiszen az összekapcsolásban szerepel t = (a, b, c, d), míg az eredeti relációban nem.

Chase-teszt veszteségmentességhez V.

