Adatbázisok 1. Analitikus adatfeldolgozás

Adattárház

Adatkocka

Adatbányászat

Áttekintés

- A hagyományos adatbázisokat sok, apró, egyszerű lekérdezésre hangolták (pl. bankbetétek vagy járatfoglalások)
- A döntéstámogató alkalmazások kevesebb, de idő igényesebb, bonyolultabb lekérdezéseket használnak, nagy mennyiségű adattal dolgoznak
- Ezért modernebb adatarchitektúrákat fejlesztettek ki azért, hogy a bonyolultabb „analitikus”, elemző jellegű lekérdezéseket kezelni tudják

Adattárház

- Jelenleg ez az egyik legelterjedtebb formája az adatintegrációnak.
  - Egyetlen egy közös adatbázisba másolják (adattárház) az adatokat és napra készen tartják.
  - Módszere: periodikus aktualizálás, gyakran éjszaka.
  - Gyakran az analitikus lekérdezések végett hozzák létre.

OLTP

- Adatbázisok tipikusan on-line tranzakció feldolgozást végeznek (OLTP).
  - Rövid, egyszerű, gyakran feltett kérdések, mindegyik viszonylag kevés sort ad vissza válaszként.
  - Pl.: Web felületen keresztüli lekérdezések és válaszok, pénztárgépnél vásárlás, repülőjegy értékesítés

OLAP

- Növekvő jelentőségű az OLAP jellegű lekérdezések.
  - Kisebb számú, de összetett, amelyek órákig is futhatnak.
  - A lekérdezések nem igénylik az abszolút időben pontos adatbázist.

OLAP

- Általában az adatbázis nagyobb részét érintik az idetartozó tranzakciók.
  - Soros végrehajtás esetén leállhatnának az OLAP-műveletek → nem igazán tolerálható
  - Nem jó megengedni valamilyen típusú új adatok felvitelét, amikor éppen fut egy konkurens OLAP lekérdezés az ilyen típusú adatokon (ami pl. átlagolja ezeket)
- Korábban ezt nevezték adatbányászatnak.

OLAP alkalmazások

- Általában az adattárházat a fogyasztásra vonatkozó adatokból állítják össze.
  - Akár terabájtnyi adatmennyiség arról, hogy melyik cikkből mennyi eladás történt
  - Előrejelzésre használható: fogyasztási adatok összesítése alapján valamilyen érdekes csoportok azonosítására

OLAP Példák

1. Amazon elemzi vásárlói viselkedését azért, hogy olyan képernyő tartalmat jelenítsen meg, amely valószínűleg érdekli a vásárlót.
2. Wal-Mart-ot az érdekli, hogy melyik régióban melyik termék értékesítése növekszik

Tipikus architektúra megoldások

- Az áruházláncok egyes áruházai OLTP szinten dolgoznak.
- A helyi adatbázisokat éjszakánként feltöltik a központi adattárházba.
- Az adatelemzők az adattárházat OLAP elemzésekre használják fel.

Csillagséma

- Csillagséma az adattárházak megszokott adatszerkezete. A következőkből áll:
  1. Ténytábla: olyan adatok kumulált tömege mint pl. az értékesítési adatok.
     - Általában csak „beillesztés”-re állított tábla.
  2. Dimenziótáblák: kisebb, általában statikus információkat tartalmaznak azokról az entitásokról, amelyekről tényeket tárolunk.

Példa csillagsémára

- Tegyük fel, hogy az adattárházban fel akarunk jegyezni minden tea értékesítési adatot: a teázót, a tea fajtáját, a vendéget, a napot, időpontot és fizetett árat.
- A ténytábla egy ilyen reláció lesz:

Értékesítések(teázó, tea, vendég, nap, idő, ár)

Példa folytatás

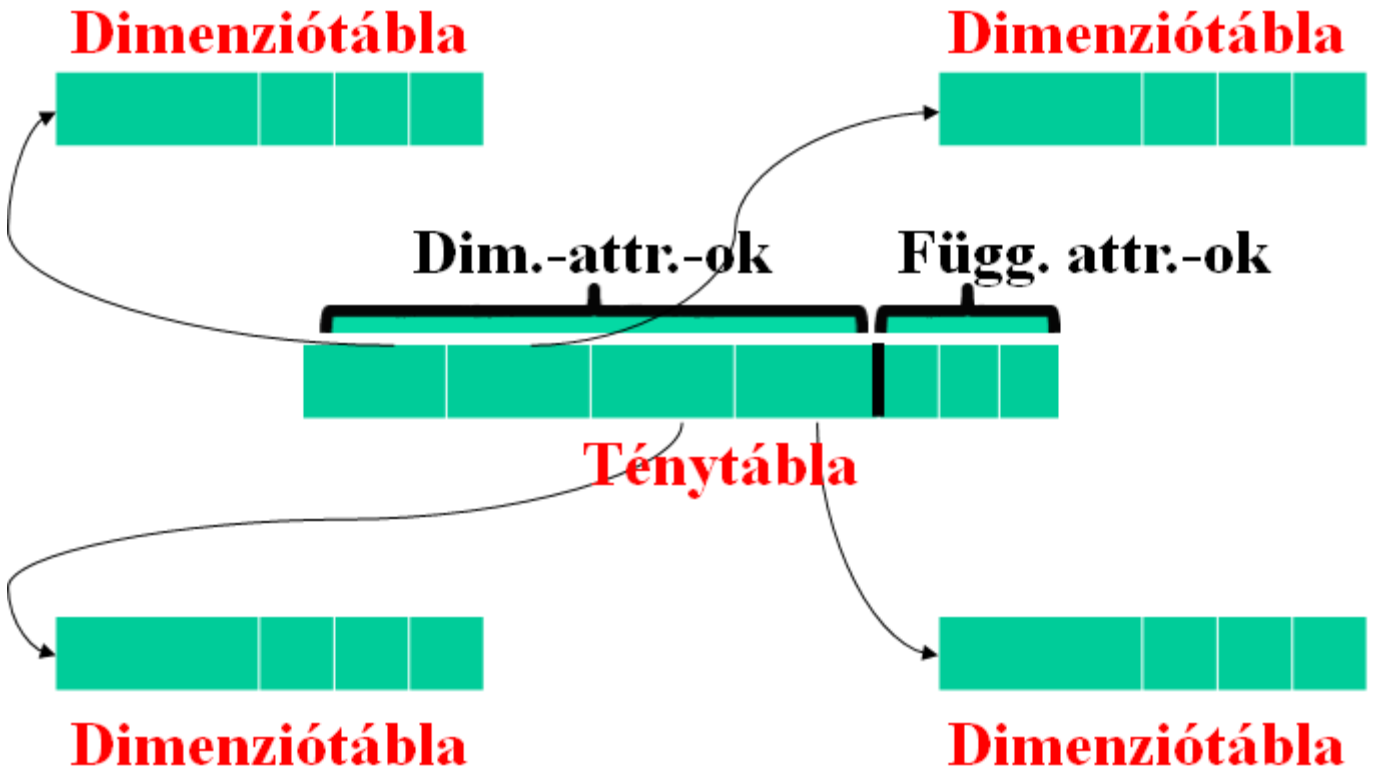
- A dimenziótáblák a teázó, a tea és a vendég adatait tartalmazzák

Dimenziók és a függő attribútumok

- A ténytáblák attribútumainak két osztálya:

1. Dimenzióattribútumok: Általában a dimenziótáblák kulcsai. (Idegen kulcsok)
2. A függő attribútum: A sorban a dimenzió attribútumok által meghatározott értékek

Dimenziók és a függő attribútumok



Példa függő attribútumok

- Az *ár* függő attribútum az *Értékesítés* relációban
- Amelyet a dimenzióattribútumok kombinációja határoz meg: a *teázó*, a *tea* és a *vendég* valamint az időpont (a *nap* és az *idő* attribútumok kombinációja)

OLAP adatok többdimenziós nézete

- Gondolhatunk úgy is a ténytáblában tárolt adatokra, mintha többdim. térben vagy „kockában” lennének elrendezve
  - A kocka belsőpontjai ábrázolják az adatobjektumokat: pl. egy-egy gépkocsi eladás.
  - A dimenziók ennek az eladásnak a jellemzőit írják le.

OLAP adatok többdimenziós nézete

- Az előbbit általában *nyers adatkockának* hívjuk, hogy megkülönböztessük az összetettebb *formális adatkockától*

OLAP adatok többdimenziós nézete

- Ez utóbbi két dologban tér el:
  1. A dimenziók részhalmazaira vett összesítéseket is tartalmazza az adatokon túl.
  2. Az itteni belső pontok az adatobjektumoknak egy kezdeti összesítését is ábrázolhatják (pl. nem az összes teának az eladásait ábrázoljuk, hanem gyártónként összesítve)

Adattárház készítési módozatok

1. *ROLAP* = relációs OLAP. Relációs adatbáziskezelő rendszer olyan hangolása, amely a csillag sémát támogatja. Itt a ténytábla a nyers: „nem összesített” adatokat tartalmazza.
2. *MOLAP* = többdimenziós OLAP: specializált adatbáziskezelő használata, amely pl. a formális adatkocka adatszerkezetet támogatja.

ROLAP technikák

```
SELECT COUNT(*)
FROM FELHASZNÁLÓK
WHERE CSALÁDI_ÁLLAPOT = 'Házas' AND RÉGIÓ IN ('Közép','Nyugat');
```

1. *Bitmap indexek*: a **dimenziótáblák** mindegyik olyan **attribútumára**, amelyek várhatóan részt fognak venni egy keresésben (pl. minden gyártóra a *Tea* relációban), egy **bitvektor** létrehozása, amely megmondja, hogy mely sorok tartalmazzák ezt az értéket.

Név	Családi_ állapot	Régió
Sue	Egyedülálló	Kelet
Tom	Házas	Közép
John	Házas	Nyugat
Ann	Elvált	Közép
Cathleen	Házas	Nyugat
Derrick	Egyedülálló	Közép

Cs._áll.='Egy'	Cs._áll.='H'	Cs._áll.='El'
1	0	0
0	1	0
0	1	0
0	0	1
0	1	0
1	0	0

Régió='Ke'	Régió='Kö'	Régió='Ny'
1	0	0
0	1	0
0	0	1
0	1	0
0	0	1
0	1	0

ROLAP technikák

2. *Materializált nézetek*: az olyan nézeteket, amelyek több lekérdezés megválaszolásához hasznosak magában az adattárházban eltárolják.

Tipikus OLAP lekérdezések

- Az OLAP lekérdezések gyakran egy csillag összekapcsolással kezdődnek: a ténytábla és a dimenziótáblák természetes összekapcsolásával.

```
SELECT *
FROM Értékesítések, Teázók, Teák,
  Vendégek
WHERE Értékesítések.teázó =
  Teázók.teázó AND Értékesítések.tea =
  Teák.tea AND Értékesítések.vendég =
  Vendégek.vendég;
```

Tipikus OLAP lekérdezések

- Tipikus OLAP lekérdezések:

1. Egy csillagséma összekapcsolással kezdődnek.
2. Leválogatják a fontos sorokat, a dimenziótáblák adatai alapján
3. Egy vagy több dimenzió alapján csoportosítanak.
4. Az eredmény egyes attribútumait összegzik

Példa: OLAP lekérdezés

- Palo Alto mindegyik teázójára keressük meg a Lipton által gyártott mindegyik teára az összes eladás értékét

1. Szűrő: *cím* = “Palo Alto” és *gyártó* = “Lipton”.
2. Csoportosítás: teázó és tea.
3. Összesítés: az *ár* összege

Példa: SQL-ben

```
SELECT teázó, tea, SUM(ár)
FROM Értékesítések NATURAL JOIN Teázók
 NATURAL JOIN Teák
WHERE cím = 'Palo Alto' AND
 gyártó = 'Lipton'
GROUP BY teázó, tea;
```

Materializált nézetek használata

- Az előbbi példa lekérdezés közvetlen végrehajtása az *Értékesítések* és a dimenziótáblák segítségével túl hosszú ideig tartana.
- Ha egy materializált nézetet hozunk létre, amely elegendő információt tartalmaz sokkal gyorsabban lehetne megválaszolni

Példa: Materializált nézetek használata

- Mely nézetek segítenék a lekérdezést:
- Kulcs kérdések:
  1. Össze kell kapcsolni minimum az *Értékesítések*, *Teázók*, és *Teák* táblákat.
  2. Csoportosítani kell legalább *teázó* és *tea* attr. szerint.
  3. Sem a Palo-Alto-i teázókat, sem Lipton teáit nem szabad kihagyni.
  4. Nem szabad lehagyni az eredményből vetítéssel sem a *cím* sem a *gyártó* attribútumokat.

Példa --- folytatás

Itt a materializált nézet:

A funkcionális függések miatt nincs igazi csoportosítás

```
CREATE MATERIALIZED VIEW TCTGE(teázó, cím, tea, gyártó, értékesítés) AS
    SELECT teázó, cím, tea, gyártó,
        SUM(ár) értékesítés
    FROM Értékesítések NATURAL JOIN Teázók NATURAL JOIN Teák
    GROUP BY teázó, cím, tea, gyártó;
```

Mivel teázó -> cím és tea -> gyártó, ezért nincs igazi csoportosítás

Szükségünk van címre és gyártóra a SELECT-ben.

Példa --- Lezárás

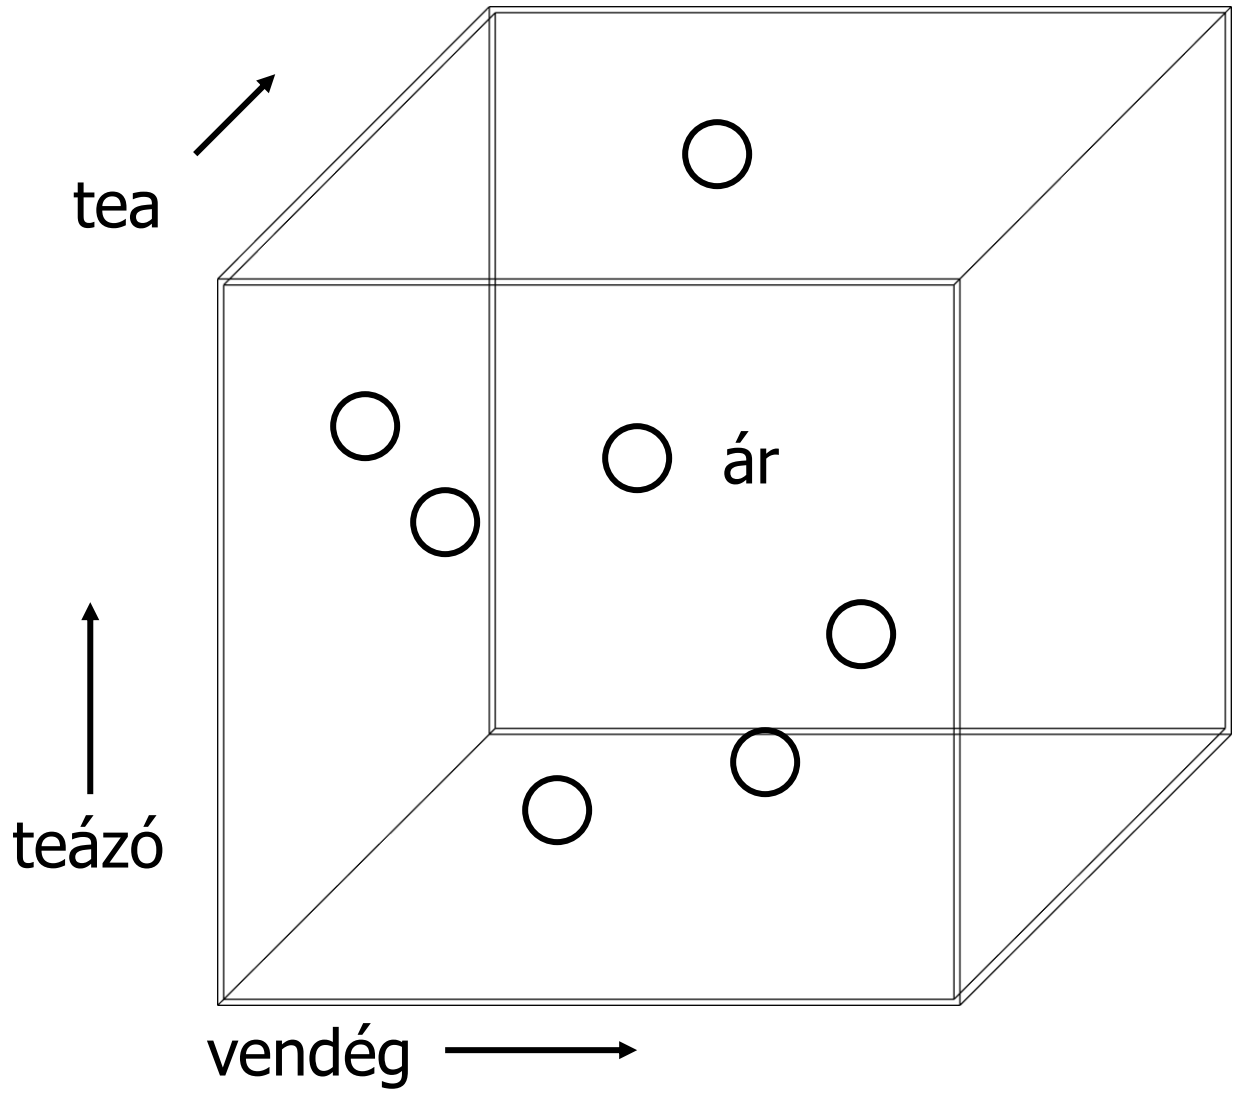
TCTGE materializált nézet lekérdezése:

```
SELECT teázó, tea, értékesítés
FROM TCTGE
WHERE cím = 'Palo Alto' AND
  gyártó = 'Lipton';
```

MOLAP és adatkockák

- A dimenzió táblák kulcsai a hiperkocka dimenziói:
  - Példa: *Értékesítések* adataira, négy dimenzió: *teázók, teákk, vendégek*, és *idő*.
- A függő attribútumok (pl. *ár*) a kocka „belső” pontjaiban jelennek meg

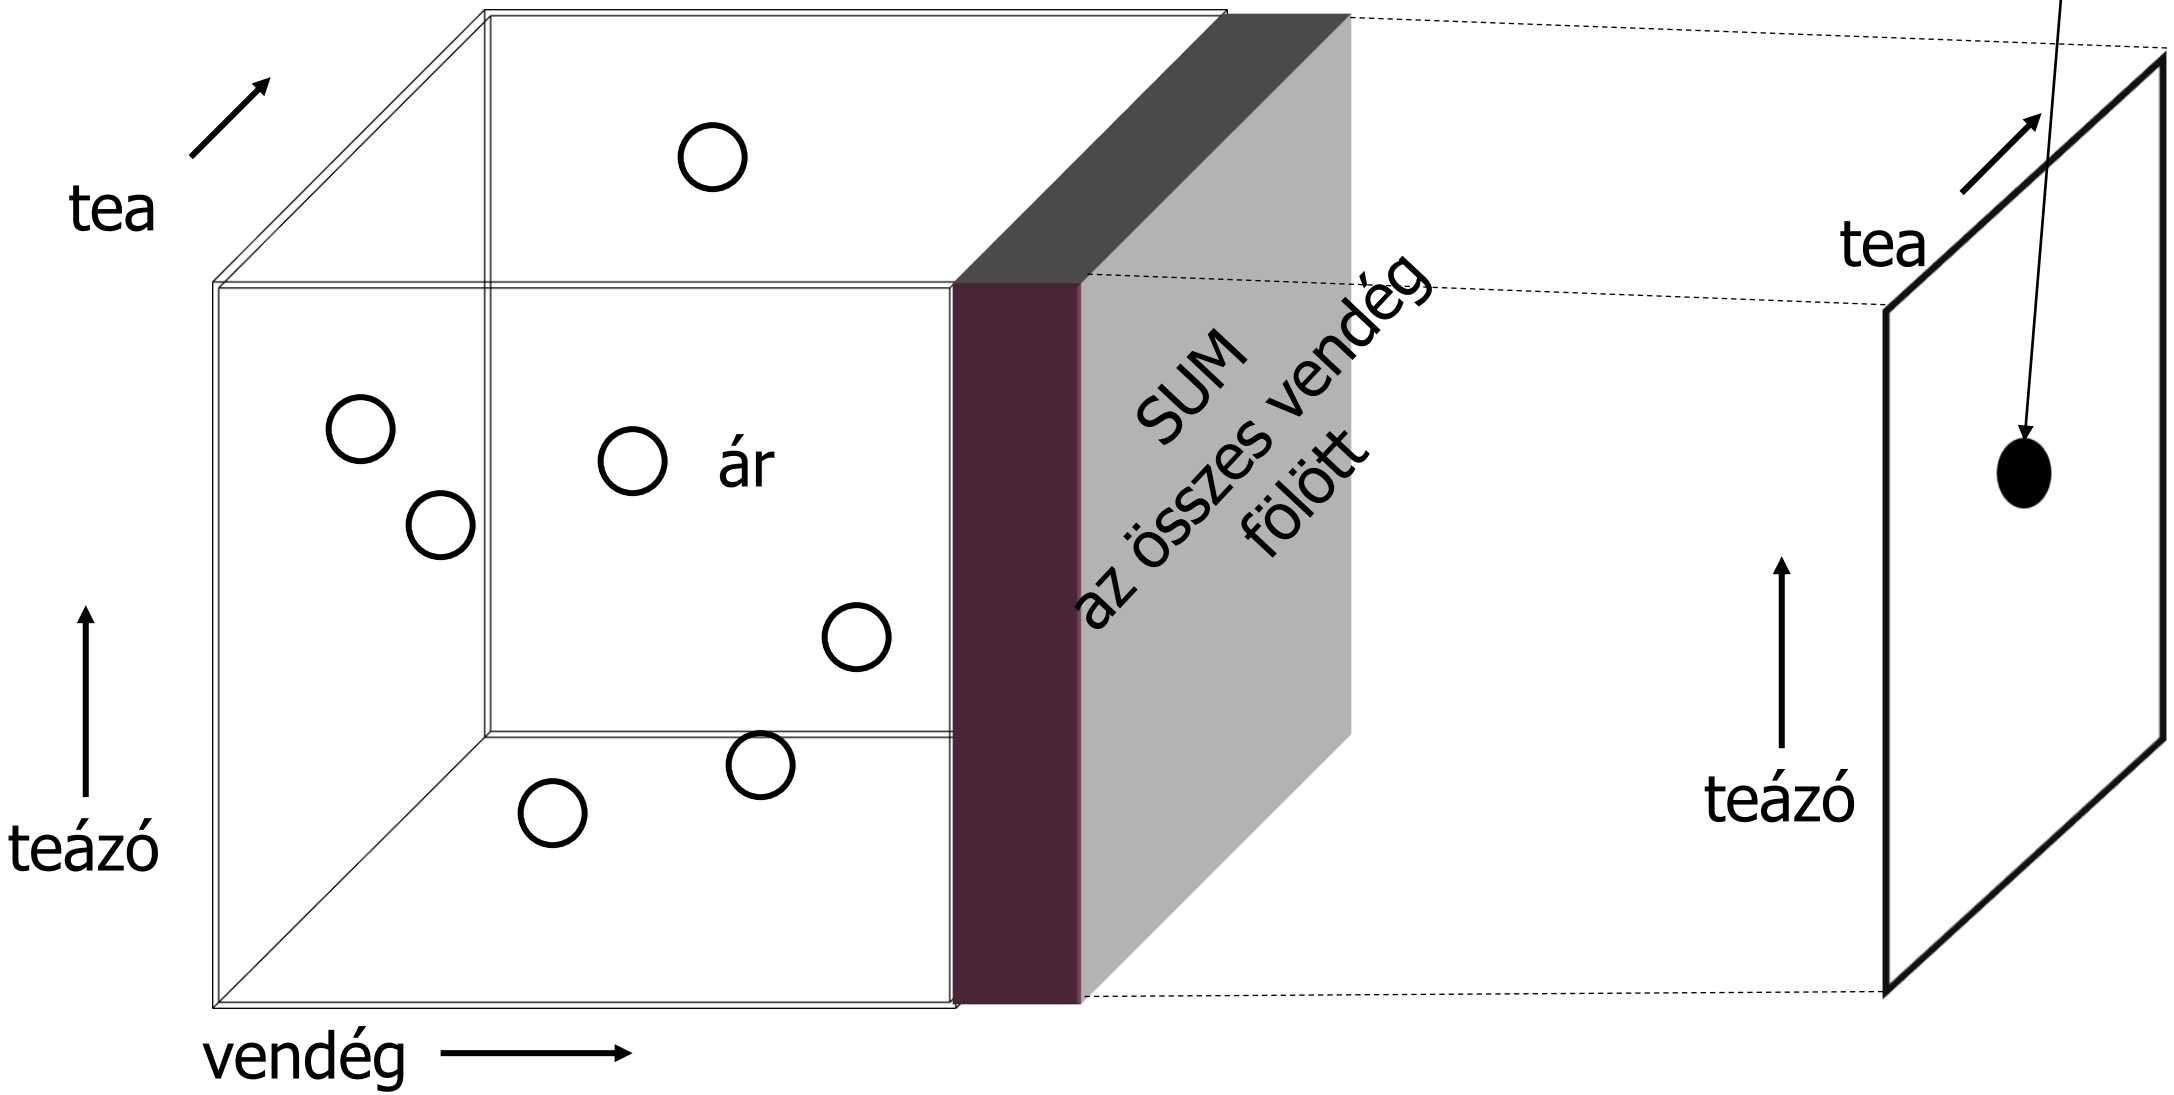
Vizualizáció -- Adatkockák



Kocka oldalai, szélei

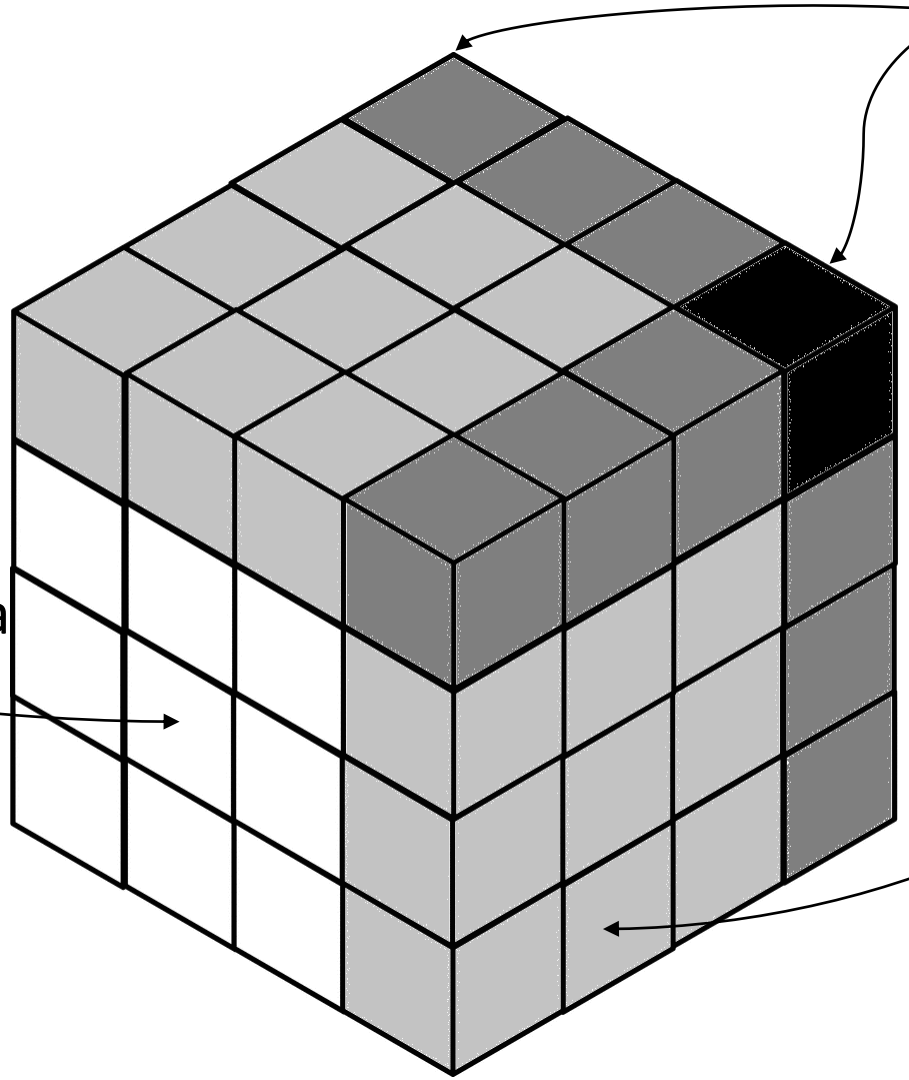
- Az adatkocka tartalmazhat összesítéseket (tipikusan SUM) a kocka oldalai szerint
  - A már említett példa: a teák dimenzióját kicseréljük a gyártóra
- A kocka szélei tartalmazhatnak összesítést egy dimenzióban, két dimenzióban, stb.

Vizualizáció --- Adatkocka összesítéssel



Példa

- A példánk 4 –dimenziós adatkockája tartalmazza az *árak* összegét, minden teázóra, teára, vendégre és időegységre (pl. napra)
- De tartalmazhatná az értékesítési adatokat, az *árak* összegét minden teázó-tea párosra, minden teázó-vendég-nap hármasra, stb.



A kocka határainak bővítése a dim.-ok minden lehetséges kombinációján kiszámított összesítéseknek megfelelő módon

Eredeti adatkocka

Lefúrás

- Lefúrás= „finomabb összegzés” = az összegzéseket finomabb alkotórészeire bontjuk.
- Példa: Ha kiderült, hogy Joe teázója nagyon kevés Lipton teát adott el.
- Bontsuk fel az értékesítési adatokat az egyes Lipton teafajták szerint!

Felgörgetés (felösszegzés)

- Felgörgetés = összegzés egy vagy több dimenzió mentén
- Példa: legyen egy olyan táblánk, amelyben minden vendégről azt tároljuk, hogy mennyi *Brisk teát* fogyasztott el az egyes teázókban, görgessük fel ezt egy olyan táblába, amelyik megadja minden vendégre azt, hogy mennyi *Brisk teát* fogyasztott el

Példa: lefúrás és felgörgetés

Lipton árai (vendég, teázó) páronként

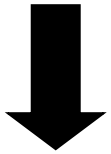
	Jim	Bob	Mary
Joe Teázó	45	33	30
Sue Teázó	50	36	42
Piros Orr	38	31	40



Felgörgetés teázók szerint

Lipton árai vendégenként

Jim	Bob	Mary
133	100	112



Lefúrás teánként

Lipton árai (tea, vendég) páronként

	Jim	Bob	Mary
Brisk	40	29	40
Pyramid	45	31	37
Yellow label	48	40	35

Az adatkocka szerkezete

- Képzeljük azt, hogy mindegyik dimenzió tartalmaz egy további értéket (*) [*A szokásos vélelmezett „tetszőleges” érték értelmezéssel*].
- Egy olyan pont, amelynek koordinátái között egy vagy több „*” szerepel azt jelenti, hogy azok fölött a dimenziók fölött, amelyeknek az értéke ebben a sorban (adatkocka pontban) „*” összegzést hajt végre.
- Pl. Értékesítések(“Joe’s Teahouse”, “Brisk”, *, *, *ár*), minden vendégre vonatkozóan, az összes eltöltött időt figyelembe véve, amikor Brisk-et fogyasztottak Joe teázójában (“Joe’s Teahouse”) a fogyasztás teljes összegét (*ár)* adja meg.

Materializált adatkocka nézetek

- Adatkockák létrehozására olyan materializált nézeteket lehet használni, amelyek egy vagy több dimenzióban összegzéseket tartalmaznak.
- Az egyes dimenziókat nem kell teljes mértékben összegezni – az egyik lehetőség, hogy a dimenzió tábla bizonyos attribútumai szerint összegzünk.

Példa

- Az értékesítés materializált nézete (*Értékesítések*), adatkocka a következő lehet:
- Vendégek alapján teljes összegzés.
- A tea fajták alapján nincs összegzés
- Idő tekintetében hetek szerinti összegzés
- A teázók városa szerinti összegzés.

Kockaművelet SQL-ben

- Az SQL támogatja a kockaműveletet: `WITH CUBE` (illetve PostgreSQL-ben, Oracle-ben: `GROUP BY CUBE(A,B)`)
- Így nem csak az egyes csoportokra vonatkozó sorokat kapjuk vissza, hanem azokat is, amelyek összesítéseket fejeznek ki a csoportosításban résztvevő egy/több dimenzióra nézve
- A soroknál a *-ot a NULL jelzi

Példa

Materializált nézet:
Értékesítések

teázó	tea	ár	darab
Joe’s teahouse	Brisk	2.5	1
Joe’s teahouse	Pyramid	3.5	1
Joe’s teahouse	Rooibos	3.0	1
Joe’s teahouse	Yellow label	2.75	1
Joe’s teahouse	Epertea	4.5	1
Joe’s teahouse	Earl Grey	3.25	1
Sue’s teahouse	Brisk	2.0	1
Sue’s teahouse	Pyramid	2.25	1
Sue’s teahouse	Earl Grey	3.75	1
Sue’s teahouse	Yellow label	2.75	1
Sue’s teahouse	Csipkebogyótea	4.0	1

```
SELECT teázó, tea, SUM(ár), SUM(darab)
FROM Értékesítések
GROUP BY teázó, tea WITH CUBE
```

teázó	tea	SUM(ár)	SUM(darab)
Joe's teahouse	Brisk	2.5	1
Joe's teahouse	Pyramid	3.5	1
Joe's teahouse	Rooibos	3.0	1
Joe's teahouse	Yellow label	2.75	1
Joe's teahouse	Epertea	4.5	1
Joe's teahouse	Earl Grey	3.25	1
Sue's teahouse	Brisk	2.0	1
Sue's teahouse	Pyramid	2.25	1
Sue's teahouse	Earl Grey	3.75	1
Sue's teahouse	Yellow label	2.75	1
Sue's teahouse	Csipkebogyótea	4.0	1
Joe's teahouse	NULL	19.5	6
Sue's teahouse	NULL	14.75	5
NULL	Brisk	4.5	2
NULL	Pyramid	5.75	2
NULL	Rooibos	3.0	1
NULL	Yellow label	5.5	2
NULL	Epertea	4.5	1
NULL	Earl Grey	7.0	2
NULL	Csipkebogyótea	4.0	1
NULL	NULL	34.25	11

Adatbányászat

- Az adatbányászat az olyan adatfeldolgozásokat jelenti, amelyek nagy adathalmazokat összegeznek valamilyen szempontból hasznos módon.
- Példák:

1. Az összes Web lap klaszterezése témák szerint.
2. A bankkártyák csalásra történő használatának jellemzőinek feltárása

Bevásárló kosár

- A relációs adatforrásokból az egyik tipikus adatbányászati feladat a *bevásárló kosár* = olyan bevásárlási tételek listája, amiket egy fogyasztó megvásárolt.
- A bevásárlási adatok egyik összegzése a *gyakran előforduló tételhalmazok* = olyan árutételek, amelyek gyakran fordulnak elő együtt.

Példa

- Ha valaki gyakran vásárol hamburgert és ketchup-ot együtt és szalma krumplit vesz még hozzá,
- akkor csináljunk egy árleszállítást a hamburgerre, viszont emeljük meg a ketchup árát.

Gyakori párosítások feltárása

- Az egyszerű eset, amikor csak a gyakori párosításokat akarjuk megtalálni.
- Tegyük fel, hogy az adatok a *Kosarak(kosár, tétel)* relációban vannak.
- Az *s támogató küszöbérték* az olyan bevásárló kosarak minimális száma, amelyben
  - egyrészt a minket érdeklő termék párosítások jelennek meg,
  - másrészt ha ezt a küszöb értéket túllépi a bevásárló kosarak száma, akkor érdekesek lesznek számunkra.

Gyakori párosítások SQL-ben

```
SELECT b1.tétel, b2.tétel
FROM Kosarak b1, Kosarak b2
WHERE b1.kosár = b2.kosár
  AND b1.tétel < b2.tétel
GROUP BY b1.tétel, b2.tétel
HAVING COUNT(*) >= s;
```

Keressük azokat a bevásárló kosár párosokat, amelyek ugyanarra a kosárra vonatkoznak, de az árutételek különböznek
Az első tételnek meg kell előznie a másikat azért, hogy ne számoljuk kétszer ugyanazt a párt.

Hozzunk létre egy csoportot minden olyan pár termékre, amelyik legalább az egyik kosárban megjelenik

Dobjuk el azokat a termékeket, amelyek nem jelennek meg legalább *s*-szer

A-Priori Trükk --- 1

- Az egyszerű megvalósítást a *Kosarak* reláció önmagával történő összekapcsolásával lehetne megoldani
- Az *a-priori algoritmus* felgyorsítja a lekérdezést, a következőképpen, egy { *i*, *j* } csak akkor éri el a támogató küszöbértéket, *s* –t, ha mind { *i* } mind { *j* } vagyis mindketten elérik.

A-Priori Trükk --- 2

- Használjunk egy materializált nézetet a gyakori termékek nyilvántartására.

```
CREATE MATERIALIZED VIEW Kosarak1 AS
SELECT * FROM Kosarak
WHERE tétel IN (
  SELECT tétel FROM Kosarak
  GROUP BY tétel
  HAVING COUNT(*) >= s
);
```

Termékek, amelyek legalább *s* kosárban megjelennek

A-Priori Algoritmus

1. Készítsünk egy *Kosarak1* materializált nézetet.
2. A nyilvánvaló lekérdezést futtassuk a *Kosarak1-en, Kosarak* helyett.
   - *Kosarak1* kiszámítása olcsó, mivel nincs benne összekapcsolás
   - *Kosarak1* –nek kevesebb sora van (valószínűleg) mint *Kosarak*-nak
     - A futási idő az összekapcsolásban érintett sorok számának négyzetével arányosan csökken.